

PORTFOLIO

Software Engineer, Machine Learning

Profile



Yeonju Park

August 31, 1999

Education

2023.09 - 2025.08

Hanyang Univ.

M.S. Artificial Intelligence

2019.03 - 2023.08

Seoul Women's Univ.

B.S. Digital Media

B.S. Software Convergence

Research Experience

2023.09 - 2025.08

CNA(Computational NeuroImage Analysis) LAB

2022.02 - 2023.02

VCMI(Visual Computing and Medical Imaging) LAB

Stacks

- **Areas of Interest**

NLP, CV, Multimodal, Data type(영상 / 그래프 / 시계열 / 시퀀스)

- **Modeling**

Transformer (BERT), Graph Neural Networks (GCN), Self Supervised Learning(BYOL)

- **Domain Knowledge**

Genomic Data (SNP), Neuroimaging (DTI, rs-fMRI, T1w), Graph Construction, Cancer Imaging(T2w)

- **Tools**

Python, PyTorch, TensorFlow, NumPy, Pandas, Scikit-learn, Linux, FSL, ANTs, DSI Studio, CIVET, TensorBoard, Jupyter Notebook, Git

Profile



Yeonju Park

August 31, 1999

Coursework

| Hanyang Univ.

- AI 관련 이수과목

고급머신러닝이론, 딥러닝기초, 컴퓨터비전, 인공지능논문연구1,
생체영상처리, 고급신경영상분석개론, 인공지능융합세미나2, AI와법

| Seoul Women's Univ.

- AI 관련 이수과목

인공지능, 기계학습, 딥러닝및응용

- CS 전공 이수과목

[컴퓨터 언어/프로그래밍]

C++프로그래밍기초, 고급C++프로그래밍, 자바프로그래밍, 모바일앱프로그래밍

[CS 이론]

자료구조, 컴퓨터알고리즘, 컴퓨터구조, 운영체제, 컴퓨터수학, 유닉스프로그래밍

[웹/데이터 엔지니어링]

웹표준언어, 웹프로그래밍, 데이터베이스기초, 데이터베이스응용, 데이터통신및네트워크

[인터랙티브 컴퓨팅]

CG프로그래밍, 컴퓨터그래픽스, VR/AR/MR프로그래밍

Contents

- **Project Summary** [p.5]

- **Projects**

- # 1 Genetic Transformer Positional Encoding 비교 연구 [p.6-7]

- # 2 멀티모달 뇌 그래프 기반 알츠하이머 분류 연구 [p.8-10]

- # 3 유전자 발현량을 기반으로 한 유전자 그래프 구축 [p.11-12]

-
- **직무 적용 계획** [p.13]

Project Summary

프로젝트	핵심 기술	트리블슈팅	결과	배운 점
#1 Genetic Transformer Positional Encoding 비교 연구 유전자 서열로 질병을 분류할 때, 언어모델의 위치 정보 처리 방식이 유효한가 [2024.12 – 2025.05] 개인연구 Data : 유전자 변이(SNP) 서열 · N=623	BERT 구조 기반 위치 인코딩 4종 비교 유전자 시퀀스 인코딩 및 토큰화 설계 데이터·하이퍼파라미터를 통제 비교 실험	문제 네 가지 위치 인코딩 간 성능 차이가 유의미하지 않음 원인 언어용으로 만들어진 위치 인코딩을 유전자 서열에 그대로 적용 — 순서의 의미가 약한 도메인에는 맞지 않는 가정이 주입됨 판단 기법 비교보다 도메인 적합성 자체를 먼저 검토해야 한다고 결론	수치 RoPE가 0.5296으로 가장 높았으나 4종 간 차이가 작아 유의미한 우열로 보지 않음 원인 데이터 희소성, 과제 난이도, 도메인에 맞지 않는 위치 인코딩 개선 위치 인코딩 대신 유전 정보를 직접 주입 또는 결합하는 설계. Transformer가 오히려 부적합한 모델일 수 있음을 검토	도메인 특성을 반영하지 못하면 최신 기법은 무의미함. 신기술 적용보다, 그 분야에서 오래 사용된 방법의 설계 및 구조 분석의 중요성을 느낌
#2 멀티모달 뇌 그래프 기반 알츠하이머 분류 연구 서로 다른 두 영상을 그래프로 fusion하면 분류 성능이 올라가는가 [2024.09 – 2024.12] 2인 팀 Data : ADNI 뇌 영상 2종(구조 · 시간에 따른 활동) · N=434	영상을 90개 영역 그래프로 변환 시간에 따른 연결 변화와 방향성 추출 모달리티 1에서 XGBoost 특징 추출 2가지 모달리티를 fusion한 다음 GCN · T-CN · Transformer 결합	문제 초기 모델 학습 실패 원인 사용한 GNN이 방향 없는 연결만 가정 — 방향성 그래프 데이터의 방향 정보가 손실됨 판단 멀티모달은 두가지 모달리티의 데이터 특성 보존이 핵심이기 때문에 방향성이 보존되는 GNN을 추가 설계하는 구조로 교체 문제 12 layer Transformer에서 학습이 진행되지 않음 원인 데이터 양에 비해 모델 복잡도가 과도하다고 판단 판단 구성 요소를 하나씩 바꿔 원인을 분리 → 실험적으로 1 layer로 축소	성능 최종 정확도 0.62 해석 구조를 줄이고 노드 특징을 단순한 상관 계수로 바꾼 쪽이 더 나은 성능 한계 데이터 규모가 작아 깊은 구조의 이점을 확인하지 못함	복잡한 모델이 항상 낫지 않다 — 데이터 규모에 적합한 복잡도 설계가 먼저다 멀티모달 구축 전, 각각이 충분한 정보를 담고 있는지 유니모달 검증의 필요성 체감
#3 유전자 발현량 기반 유전자 그래프 구축 뇌 부위별 유전자 발현량으로 유전자 사이의 관계 네트워크를 만들 수 있는가 [2023.09 – 2024.04] 개인 과제 Data : AHBA 뇌 부위별 유전자 발현량 + 뇌 MRI · N=6	측정 단위를 유전자 x 뇌 영역 단위로 계산 및 데이터 재구성 발현 패턴 유사도로 유전자 네트워크 구축 뇌 영역 크기와 발현량의 관계 분석 분석 데이터 기반 유전자 그래프 구축	문제 처음 목표였던 영역 간 연결성 분석에 필요한 영상 데이터가 보유 자료에 없음 판단 보유한 데이터 내에서 기존 목표와 유사한 결과를 내기 위해 수행할 수 있는 분석 재검토 해결 유전자 발현량 중심으로 분석 목표를 재설계하고 새로운 방향 제안	산출 발현량 → 유전자 관계 → 네트워크 분석 파이프라인 구축 추가 뇌 영역 크기와 발현량의 관계도 분석 한계 표본 수가 매우 적어 일반화는 어려움	데이터가 목표를 지탱하지 못할 때, 목표를 재정 의하는 판단도 분석의 일부다 이후 재사용 및 응용까지 고려해 데이터 구조를 설계해야 함

#1 Genetic Transformer Positional Encoding 비교 연구

[2024.12 – 2025.05] | 개인연구

프로젝트 개요

- Bioinformatics 시퀀스 데이터 기반 질병 분류에서 Positional Encoding 방식이 모델 성능에 미치는 영향을 분석
- 동일한 BERT 구조에서 4가지 Positional Encoding (Sinusoidal, Learnable, RoPE, ALiBi) 비교
- Positional Encoding만 변경한 통제 실험 설계

문제

- LLM에서 발전하는 최신 Positional Encoding(PE) 기법들이 유전체 Transformer 연구에는 보수적으로 적용되고 있다는 연구 공백을 발견.
- SNP 시퀀스라는 비언어적 도메인에서 PE 선택이 성능에 미치는 영향을 정량적으로 규명하고자 함.

목표


- 동일한 BERT 구조에서 Sinusoidal / Learnable / RoPE / ALiBi만 변경하여 PE 자체의 영향을 검증

담당 역할

- 연구 설계 및 가설 수립
- PLINK SNP 데이터 전처리
- Diploid Encoding · k-mer(k=4) Tokenization 구현 — 대립유전자 쌍 보존, 지역적 문맥 포착
- 4가지 Positional Encoding 구현
- Hyperparameter 통제 실험 설계 및 결과 분석

Diploid	Alternative Character	Diploid	Alternative Character
AA	A	CG or GC	F
AC or CA	B	CT or TC	H
AG or GA	D	GG	G
AT or TA	E	GT or TG	I
CC	C	TT	T

[Diploid Encoding]



#1 Genetic Transformer Positional Encoding 비교 연구

결과

- RoPE가 4가지 Positional Encoding 중 Accuracy와 F1에서 가장 높은 성능을 기록하며, SNP 시퀀스 분류에서 Relative Positional Encoding의 활용 가능성 확인

PE	Accuracy	F1 Score	Precision	Recall
Sinusoidal	0.5240	0.5304	0.4963	0.5695
Learnable	0.5280	0.5042	0.5000	0.5085
RoPE	0.5296	0.5311	0.5015	0.5644
ALiBi	0.5200	0.5215	0.4925	0.5542

Comparative analysis results of the four positional encoding techniques in the Transformer model for AD/NC classification.

한계점

- 소규모 데이터셋 (N=623) 으로 인한 일반화 한계
- AD/NC Classification 자체의 높은 Task 난이도
- 일반적으로 신호가 가장 강한 APOE만 사용하는 선행 연구와 달리, AlzGene 기준 상위 10개 유전자 전체 사용 → 시퀀스 길이, 유전적 다양성 증가로 분류 난이도 상승

결과 해석 및 향후 연구 방향

- 절대 성능 수치를 고려할 때 SNP와 같은 비언어적, 비연속 시퀀스에서는 기존 positional encoding이 오히려 잘못된 inductive bias로 작용할 가능성을 실험적으로 시사
- 후속 연구로 도메인 특성에 맞는 새로운 PE 설계 가능성 탐색
 - 위치 인코딩 없이 genomic prior만 주입
 - 기본 PE + prior 결합 방식을 구상
- Whole genome-wide SNP 데이터 활용 시 시퀀스 다양성 확보 및 모델 일반화 가능성 검토

#2 멀티모달 뇌 그래프 기반 알츠하이머 분류 연구

[2024.09 – 2024.12] | 대학원 수업 프로젝트 / 2인 팀 프로젝트

프로젝트 개요

- 뇌의 구조적 연결성(DTI)과 기능적 연결성(rs-fMRI) 데이터를 융합하여 멀티모달 뇌 그래프 기반 질병 분류 모델 설계
- 정적 연결성의 한계를 보완하기 위해 Dynamic Functional Connectivity(FC)와 Effective Connectivity(EC) 활용
- Graph Fusion 및 Transformer 기반 모델을 통해 분류 성능을 향상시키고자 함

문제

- **Static FC의 한계** : 기존 fMRI Graph는 뇌 영역 간 정적인 상관관계에 주로 의존하여 시간에 따라 변화하는 뇌 활동과 방향성 있는 상호작용을 충분히 반영하기 어려움
- **단일 modality의 한계** : fMRI만으로는 기능적 연결은 표현할 수 있지만, 실제 신경 연결의 물리적 구조를 함께 고려하기 어려움


목표

- DTI와 rs-fMRI에서 구조적·기능적·인과적 연결성 Graph를 구축 및 융합하여 NC/MCI를 분류하는 멀티모달 모델 개발

담당 역할

- 연구 설계 및 가설 수립
- DTI/rs-fMRI Raw 데이터 전처리 및 QC
- 멀티모달 뇌 그래프 생성 파이프라인 설계 및 구현

- DTI 데이터 전처리 및 그래프 구축
 - DSI Studio 기반 DTI tractography
 - AAL90 atlas 적용 및 90×90 Connectivity Matrix 생성
 - Fiber count 기반 Structural Graph 구축
- DTI 데이터 feature 추출
 - DTI Connectivity Matrix Log Transform & Z-score normalization
 - Upper triangle vectorization → 4,005개 connectivity feature 구성
 - XGBoost 기반 Top-30 중요 structural edge 선정
- rs-fMRI 그래프 구축 및 DTI Fusion
 - rs-fMRI 기반 Dynamic FC / EC graph 구축
 - 선정된 DTI edge를 FC graph에 결합하는 Structural-Functional Graph Fusion



#2 멀티모달 뇌 그래프 기반 알츠하이머 분류 연구

[2024.09 – 2024.12] | 대학원 수업 프로젝트 / 2인 팀 프로젝트

담당한 핵심 구현 3가지

1. Dynamic Functional Connectivity


Sliding Window 기반으로 rs-fMRI를 분할하여 시간에 따라 변화하는 ROI 간 기능적 연결성을 Graph로 구성

2. Effective Connectivity

Transfer Entropy를 활용하여 단순 상관관계를 넘어 뇌 영역 간 정보 흐름의 방향성을 Graph로 표현

3. Structural-Functional Fusion

DTI에서 선별한 주요 Structural Edge를 FC Graph에 결합하여 해부학적 연결 정보를 기능적 연결 학습에 반영




#2 멀티모달 뇌 그래프 기반 알츠하이머 분류 연구

[2024.09 – 2024.12] | 대학원 수업 프로젝트 / 2인 팀 프로젝트

트러블슈팅 #1 방향성 정보 보존

- 문제 : 초기 모델의 학습 실패
- 원인 분석 : 기존 GCN은 Undirected Graph를 가정하여 EC의 방향성 정보를 충분히 반영하기 어려움
- 해결 방법 : EC의 directed edge를 보존할 수 있도록 Directed GCN으로 구조 변경



트러블슈팅 #2 모델 구조 변경 후 성능 개선 시도

- 문제 : 초기 세팅인 12-layer Transformer에서 학습이 진행되지 않음
- 원인 분석 : 제한된 학습 데이터에 비해 GCN-TCN-Transformer로 이어지는 모델의 복잡도가 높아 안정적인 학습이 어려웠을 가능성이 있다고 판단
- 해결 방법 : 구성 요소를 하나씩 변경하며 원인 분석

검증 요소	실험
Transformer layer	12 layers → 1 layer → 제거
Node feature	Pearson correlation ↔ BOLD signal
Temporal Modeling	TCN 적용 / 제거
Multimodal	DTI fusion 적용 여부
Regularization	Dropout 0.2 → 0.4

Results

- Transformer 12 layers → 학습 실패
- Transformer 1 layer → 학습 정상화
- Transformer 제거 + Pearson correlation → **ACC 0.62**

Insight

- Model Complexity : 복잡한 모델이 항상 높은 성능으로 이어지는 것은 아니며, 데이터 규모에 적합한 모델 복잡도 설계가 중요함을 확인
- Multimodal Fusion : 멀티모달 융합 이전에 각 단일 모달리티에서 충분한 표현력을 확보하는 것이 선행되어야 한다고 판단

#3 유전자 발현량을 기반으로 한 유전자 그래프 구축

[2023.09 – 2024.04] | 개인 과제

프로젝트 개요


- AHBA의 뇌 영역별 유전자 발현 데이터와 뇌 영역 정보(AAL90)를 결합해 유전자 간 관계를 그래프로 구조화
- 뇌 영역별 유전자 발현량 구축 → 유전자 간 상관관계 분석 → Gene Graph 구축 파이프라인 설계
- 뇌 영역별 구조 정보와 유전자 발현량의 상관관계를 분석해 유전자별 발현 특성 확인

문제

- 초기에는 유전자 발현과 뇌 연결성을 함께 분석하는 Connectome 구성을 목표로 했으나, 사용한 AHBA 데이터에는 연결성 분석에 필요한 데이터가 없어 연결성 분석이 불가능
- 확보 가능한 Microarray 및 MRI 정보만으로도 분석 목적을 유지할 수 있도록 연구 범위를 재설계할 필요가 있었음

담당 역할 (개인 과제)

- 분석 목표 및 전체 파이프라인 설계
- 유전자 발현 데이터 (AHBA Microarray) 전처리
- Probe 단위 발현값 → Gene 단위 통합
- 3D sample coordinate → voxel 좌표 기반 최근접 AAL Region 매핑
- Region-Gene Expression 행렬 구축 및 결측 영역 처리
- 유전자 간 발현 상관관계(Gene Co-expression) 분석
- 유전자 발현량과 뇌 영역별 Volume 간 상관관계(Regional Expression) 분석
- Gene Graph의 Node / Edge 구성 기준 설계 및 구축
- 결과 분석 및 보고서 작성



#3 유전자 발현량을 기반으로 한 유전자 그래프 구축

[2023.09 – 2024.04] | 개인 과제

주요 설계 판단

고민 사항	검토	최종 선택
유전자 발현량 분석 단위	개별 Sample 위치 vs 뇌 영역	AAL 90 Region 단위
유전자 발현량과 비교할 뇌 구조 정보	Volume / Cortical Thickness / Surface Area	Volume
유전자 간 연결 기준	발현 패턴의 상관계수 기준	PCC ≥ 0.7

트러블슈팅 #1 데이터 제약에 따른 분석 방향 재설계


- 문제 : 초기 목표였던 뇌 영역 간 연결성 분석에는 fMRI/DTI가 필요했지만, 사용한 AHBA 데이터에는 해당 데이터가 존재하지 않았음.
- 판단 : 확보 가능한 Microarray와 MRI 데이터로 분석 가능한 범위를 재검토하고, 유전자 발현량을 중심으로 분석 목표를 재설계
- 행동 : 뇌 영역별 유전자 발현량을 구축한 뒤 유전자 간 발현 관계를 분석하고, 뇌 영역별 구조 정보와 유전자 발현량의 관계를 추가 분석하는 방향으로 파이프라인 변경
- 결과 : Region-Gene Expression → Gene Co-expression → Gene Graph로 이어지는 분석 파이프라인을 구축하고, MRI Volume을 활용한 Regional Expression 분석까지 수행

Limitation

- 극도로 적은 AHBA subject 수로 일반화에 한계가 있으며, 정적 유전자 발현 데이터를 사용해 시간에 따른 발현 변화를 반영하지 못함.

Insight

- 사용 가능한 데이터를 검토해 지시받은 최초 분석 목표를 수행 가능한 범위로 재설계하고, 새로운 분석 방향을 제안하는 과정을 경험함
- 개별 Sample의 유전자 발현량을 뇌 영역 단위로 변환하는 과정에서, 현재 분석뿐 아니라 후속 연구에서의 활용 가능성까지 고려해 데이터 구조를 설계하는 관점을 배움



[최종 산출물]

THANK YOU

Yeonju Park

Phone : 010-4947-6003

E-mail : yeonju9831@gmail.com